Gộp GPU qua mạng: 2 card so với 3 card (llama.cpp GGML RPC, chế độ `merged`)

Ngày đo 08/11/2026. Chỉ đo hiệu suất, không đo chất lượng code. Mọi số liệu là số đo thực; phần suy luận được gắn [ƯỚC TÍNH].

1. Kết luận

1. **Thêm card thứ ba qua Wi-Fi làm chậm đi ở mọi chỉ số.** Qwen3-Coder-30B: decode giảm 61% (125,8 → 48,9 tok/s), prefill giảm 62%, tải model lâu gấp 2,6 lần, điện năng mỗi token gần gấp đôi. Qwen3.8-27B: decode giảm 30%, prefill giảm 64%.
2. **Nguyên nhân là đường mạng, không phải GPU.** Hai card nối qua Wi-Fi (3060 + 3060) chỉ đạt 53 tok/s, gần bằng 3 card (49 tok/s), trong khi hai card nối Ethernet đạt 126 tok/s. Tốc độ do đường mạng chậm nhất quyết định. Cùng cặp GPU 5070 + 3060 như production, chỉ đổi đường tới 5070 từ Ethernet sang Wi-Fi thật đã làm decode giảm 43% (125,8 → 72,1 tok/s).
3. **2 card chỉ qua Wi-Fi (5070 + 3060, đo trên Wi-Fi thật) vẫn chậm hơn Ethernet rõ rệt:** Coder-30B 72,1 tok/s (−43%), Qwen3.8-27B 20,3 tok/s (−15%), prefill giảm 81–83%, tải model lâu gấp 6–6,5 lần; nhưng decode nhanh hơn 3 card (48,9 và 16,7 tok/s).
4. **Giảm số tầng đặt lên card Wi-Fi gần như không giúp** (từ 32% xuống 18% tầng: 48,9 → 50,5 tok/s), vì mỗi nút từ xa tốn một chi phí cố định cho mỗi token.
5. **Card thứ ba có ích khi model không vừa 2 card.** Với Qwen3-Coder-30B bản Q6_K (25,1 GB), 2 card không nạp nổi; 3 card chạy được ở 49,6 tok/s, nhanh hơn phương án 2 card cộng đẩy expert sang CPU (30,1 tok/s) 65% ở một luồng. Tuy vậy Q4_K_M trên 2 card vẫn nhanh gấp 2,5 lần (125,8 tok/s).
6. **Khuyến nghị:** giữ 2 card qua Ethernet cho production; chỉ thêm card thứ ba khi nó nối Ethernet cùng cấp hoặc khi model không vừa 2 card.

2. Điều kiện đo

Nút	GPU	Đường nối	RTT trung bình (tối đa)	Băng thông TCP đo thực (đi / về)
Linux (master)	RTX 3060 12 GB	không áp dụng	không áp dụng	không áp dụng
Windows `pc-win-01`	RTX 5070 12 GB	**Ethernet 2,5 GbE**	**0,32 ms** (0,66 ms)	**297 / 297 MB/s**
Windows `fi-ai03`	RTX 3060 12 GB	**Wi-Fi**	**4,9 ms** (20,3 ms)	**36,7 / 50,6 MB/s**
Windows `pc-win-01` (đo lại qua Wi-Fi)	RTX 5070 12 GB	**Wi-Fi 802.11ax** (cùng máy, đổi sang card Wi-Fi)	**4,0 ms** (19,2 ms)	**25,0 / 29,5 MB/s**

Wi-Fi chỉ đạt 8–17% băng thông của Ethernet và có độ trễ gấp 10–15 lần. Trường hợp "5070 qua Wi-Fi" đo thật: máy 5070 kết nối Wi-Fi (192.168.1.78) và master gọi rpc-server qua địa chỉ Wi-Fi đó; điều khiển vẫn qua Ethernet. Cấu hình giống production: chia theo tầng, KV f16, flash attention; trọng số đẩy qua RPC từ trạng thái nguội. Số đo 2 card khớp benchmark production trước đó trong khoảng 1–2%.

3. Kết quả: 2 card so với 3 card (Q4_K_M)

Qwen3-Coder-30B-A3B (MoE, 18,6 GB)

Chỉ số	2 card (Ethernet)	3 card (+ Wi-Fi)	Thay đổi
Thời gian tải model	71,5 s	189,4 s	+165%
Prefill 2.079 token	3.258 tok/s	1.234 tok/s	−62%
Decode một luồng	**125,8 tok/s**	**48,9 tok/s**	**−61%**
TPOT	7,95 ms	20,44 ms	+157%
Độ giật p99 giữa hai token	11,0 ms	31,1 ms	gấp 2,8 lần
Thông lượng 4 luồng song song	211,7 tok/s	92,5 tok/s	−56%
Điện năng (3 GPU)	1,60 J/token	3,16 J/token	+97%
VRAM đỉnh mỗi card	Linux 9,2 · 5070 11,3 GB	Linux 6,1 · 5070 8,3 · 3060 6,7 GB	giảm 26–34%

Qwen3.8-27B (dense, 16,5 GB)

Chỉ số	2 card (Ethernet)	3 card (+ Wi-Fi)	Thay đổi
Thời gian tải model	54,1 s	131,2 s	+142%
Prefill 2.079 token	718,5 tok/s	258,7 tok/s	−64%
Decode một luồng	**23,8 tok/s**	**16,7 tok/s**	**−30%**
TPOT	41,96 ms	59,80 ms	+43%
Độ giật p99 giữa hai token	45,6 ms	80,4 ms	gấp 1,8 lần
Thông lượng 4 luồng song song	46,0 tok/s	18,3 tok/s	−60%
Điện năng (3 GPU)	9,48 J/token	12,48 J/token	+32%
VRAM đỉnh mỗi card	Linux 8,6 · 5070 9,3 GB	Linux 6,2 · 5070 6,6 · 3060 5,7 GB	giảm 28–29%

Trường hợp 2 card, đường tới 5070 chỉ qua Wi-Fi (đo thật)

Cùng cặp GPU production (RTX 3060 Linux + RTX 5070), chỉ thay đường Ethernet tới 5070 bằng Wi-Fi thật của máy 5070 (RTT 4,0 ms, 25,0 / 29,5 MB/s; xem mục 2).

Qwen3-Coder-30B-A3B

Chỉ số	2 card Ethernet	2 card Wi-Fi (5070 + 3060)	3 card (Ethernet + Wi-Fi)
Thời gian tải model	71,5 s	466,9 s	189,4 s
Prefill 2.079 token	3.258 tok/s	562 tok/s	1.234 tok/s
Decode một luồng	125,8 tok/s	**72,1 tok/s**	48,9 tok/s
TPOT	7,95 ms	13,87 ms	20,44 ms
Độ giật p99 giữa hai token	11,0 ms	18,4 ms	31,1 ms
Thông lượng 4 luồng song song	211,7 tok/s	84,5 tok/s	92,5 tok/s
Điện năng (GPU)	1,60 J/token	2,23 J/token	3,16 J/token

Qwen3.8-27B

Chỉ số	2 card Ethernet	2 card Wi-Fi (5070 + 3060)	3 card (Ethernet + Wi-Fi)
Thời gian tải model	54,1 s	319,6 s	131,2 s
Prefill 2.079 token	718 tok/s	139 tok/s	259 tok/s
Decode một luồng	23,8 tok/s	**20,3 tok/s**	16,7 tok/s
TPOT	41,96 ms	49,18 ms	59,80 ms
Độ giật p99 giữa hai token	45,6 ms	166,7 ms	80,4 ms
Thông lượng 4 luồng song song	46,0 tok/s	13,4 tok/s	18,3 tok/s

Nhận xét: chuyển 2 card từ Ethernet sang Wi-Fi làm decode Coder-30B giảm 43% và 27B giảm 15%; prefill giảm 83% và 81%; thời gian tải gấp 6,5 và 5,9 lần; thông lượng 4 luồng giảm 60% và 71%. Dù vậy 2 card Wi-Fi vẫn nhanh hơn 3 card ở decode (+47% và +22%) và ở điện năng mỗi token trên Coder-30B. Ngược lại 3 card có prefill tốt hơn (1.234 so với 562 tok/s) vì băng thông được chia cho hai đường. Với 27B, Wi-Fi của máy 5070 làm độ giật p99 tăng lên 167 ms (Ethernet 45,6 ms).

4. So sánh nguyên nhân

Năm cấu hình trên Coder-30B, chỉ khác đường nối và số card:

Cấu hình	Decode	TPOT	Prefill 2.079	Tải model	Thông lượng 4 luồng
2 card, Ethernet (3060 + 5070)	**125,8 tok/s**	7,95 ms	3.258 tok/s	71,5 s	211,7 tok/s
2 card, Wi-Fi thật (5070 + 3060)	72,1 tok/s	13,87 ms	562 tok/s	466,9 s	84,5 tok/s
2 card, Wi-Fi thật (3060 + 3060)	53,3 tok/s	18,75 ms	827 tok/s	214,4 s	83,4 tok/s
3 card (32 / 36 / 32% tầng)	48,9 tok/s	20,44 ms	1.234 tok/s	189,4 s	92,5 tok/s
3 card, giảm tải Wi-Fi (18% tầng)	50,5 tok/s	19,79 ms	1.270 tok/s	110,2 s	102,2 tok/s

Các cấu hình có Wi-Fi thật đều chỉ đạt 49–53 tok/s dù khác nhau về số card và tỷ lệ chia tầng. Hai kết quả từ cấu hình 5070 + 3060 trên Wi-Fi thật:

- **Riêng đường mạng đã gây ra phần lớn sự sụt giảm.** Cùng cặp 5070 + 3060, đổi từ Ethernet sang Wi-Fi: decode giảm 43% (125,8 → 72,1 tok/s), prefill giảm 83% (3.258 → 562), thông lượng 4 luồng giảm 60% (211,7 → 84,5), thời gian tải model gấp 6,5 lần (71,5 → 466,9 s).
- **GPU mạnh hơn chỉ giúp một phần.** Cặp có RTX 5070 trên Wi-Fi nhanh hơn cặp 3060 + 3060 trên Wi-Fi 35% (72,1 so với 53,3 tok/s) nhưng vẫn kém Ethernet gần một nửa. Với 2 card, tốc độ trên Wi-Fi (72,1) cao hơn 3 card 47% (48,9): card thứ ba gây thiệt hại lớn hơn việc chỉ hạ chất lượng một đường.
- **Băng thông Wi-Fi quyết định prefill và thời gian tải.** Wi-Fi của máy 5070 đo 25,0 / 29,5 MB/s, thấp hơn Wi-Fi của `fi-ai03` (36,7 / 50,6 MB/s), nên tải model mất 467 s (so với 214 s của cặp 3060 + 3060 chỉ gửi một nửa model qua Wi-Fi).

Ba cơ chế giải thích:

- **Decode bị chi phí cố định mỗi token chi phối.** Mỗi token kéo theo khoảng 0,3 MB qua mỗi đường RPC. Qua Wi-Fi, truyền 0,3 MB mất khoảng 6–8 ms, cộng chênh lệch RTT khoảng 4,6 ms, tổng khoảng 11–13 ms [ƯỚC TÍNH]; thực tế TPOT tăng 10,8 ms (7,95 → 18,75). Chi phí này không phụ thuộc số tầng đặt trên card từ xa, nên giảm tầng không giúp.
- **Prefill bị giới hạn băng thông.** Prefill chuyển lượng dữ liệu tỷ lệ với số token: Ethernet dùng khoảng 1.100–1.230 Mbps, còn Wi-Fi chạm trần ở khoảng 225–295 Mbps, sát băng thông đo được.
- **Tải model bị giới hạn bởi nhánh chậm nhất.** Trọng số đẩy qua Ethernet đạt khoảng 137–140 MB/s, qua Wi-Fi chỉ 31–46 MB/s; thời gian tải của 3 card do phần 6,2 GB gửi sang card Wi-Fi quyết định.

Model dense Qwen3.8-27B nhạy với đường mạng theo cách khác:

Cấu hình	Decode	TPOT	Prefill 2.079	Tải model	Thông lượng 4 luồng
2 card, Ethernet (3060 + 5070)	**23,8 tok/s**	41,96 ms	718 tok/s	54,1 s	46,0 tok/s
2 card, Wi-Fi thật (5070 + 3060)	20,3 tok/s	49,18 ms	139 tok/s	319,6 s	13,4 tok/s
3 card (+ Wi-Fi)	16,7 tok/s	59,80 ms	259 tok/s	131,2 s	18,3 tok/s

Decode chỉ giảm 15% vì mỗi token tốn nhiều thời gian tính toán (42 ms), nên 7,2 ms thêm từ mạng chiếm tỷ lệ nhỏ; ngược lại prefill giảm 81% vì bị giới hạn băng thông. Ở model này, 2 card trên Wi-Fi vẫn tốt hơn 3 card về decode (+22%) nhưng kém về prefill (−46%) và thông lượng 4 luồng (−27%).

Hệ quả phụ: GPU nhàn rỗi hơn khi chờ mạng (công suất card Linux từ 101 W xuống 50 W) nhưng mỗi token tốn thời gian hơn, nên điện năng mỗi token tăng; độ giật giữa hai token cũng tăng theo jitter của Wi-Fi.

5. Model lớn hơn dung lượng 2 card: Qwen3-Coder-30B-A3B bản Q6_K (25,1 GB)

Q6_K vượt VRAM dùng được của 2 card (khoảng 22,7 GB) nhưng vừa 3 card (khoảng 34,5 GB).

Chỉ số	2 card thuần	2 card + 14 lớp expert trên CPU	3 card	3 card so với 2 card + CPU
Chạy được	**Không** (hết bộ nhớ GPU khi cấp bộ đệm tính toán)	Có	Có	không áp dụng
Thời gian tải model	không áp dụng	69,3 s	247,5 s	gấp 3,6 lần (chậm hơn)
Prefill 2.079 token	không áp dụng	396 tok/s	1.074 tok/s	gấp 2,7 lần
Decode một luồng	không áp dụng	30,1 tok/s	**49,6 tok/s**	+65%
Độ giật p99 giữa hai token	không áp dụng	78,6 ms	35,6 ms	ổn định hơn
Thông lượng 4 luồng song song	không áp dụng	58,7 tok/s	60,3 tok/s	ngang nhau (+3%)
Điện năng (GPU)	không áp dụng	3,32 J/token	3,26 J/token	ngang nhau

- 3 card cho phép chạy toàn bộ trên GPU và nhanh hơn phương án đẩy expert sang CPU ở độ trễ một luồng, nhưng lợi thế biến mất khi có 4 luồng song song và việc tải model chậm hơn nhiều.
- Q6_K trên 3 card (49,6 tok/s) gần bằng Q4_K_M trên 3 card (48,9 tok/s): khi nút thắt là mạng, tăng độ chính xác lượng tử hóa gần như không tốn thêm tốc độ.
- So với Q4_K_M trên 2 card (125,8 tok/s), Q6_K trên 3 card chậm hơn 61% và tốn điện gấp đôi mỗi token. Chỉ nên dùng nếu Q6_K cho kết quả tốt hơn rõ rệt, điều chưa được đo.

6. Khuyến nghị

1. Giữ `merged` 2 card qua Ethernet cho production.
2. Không đưa nút Wi-Fi vào nhóm `merged` nếu cần tốc độ.
3. Dùng card thứ ba cho việc khác (bản sao độc lập cho tác vụ song song) hoặc chỉ gộp khi model không vừa 2 card.
4. Nếu muốn 3 card trong một nhóm `merged`, nối card thứ ba bằng Ethernet cùng cấp (RTT dưới 1 ms, trên 250 MB/s) rồi đo lại; dự đoán tốc độ khi đó gần 2 card là [ƯỚC TÍNH].

7. Giới hạn

- Wi-Fi là môi trường chung, chất lượng thay đổi theo thời điểm; mỗi cấu hình Wi-Fi chỉ đo một lượt.
- Mỗi cấu hình chạy một lượt (mỗi phép đo lặp 2–3 lần, lấy trung vị); biến động của Wi-Fi chưa được định lượng. Băng thông Wi-Fi đo riêng dao động 36,7–50,6 MB/s.
- Dùng prompt tổng hợp có độ dài cố định, nên không đại diện cho tải thực; lưu lượng Wi-Fi lấy từ bộ đếm card mạng có thể lẫn lưu lượng khác; điện năng chỉ gồm công suất board GPU.
- Card thứ ba là RTX 3060 (cùng loại card master). Chất lượng của Q6_K so với Q4_K_M chưa được đo.

Dữ liệu thô: `benchmarks/reports/perf3node/*.json`.