llama.cpp: thông lượng 2 luồng thấp hơn một luồng đơn, nguyên nhân và cách xử lý

Ngày đo 09/11/2026. Máy: Linux RTX 3060 12 GB; llama-server build 11913; Qwen3-4B và Qwen3-8B Q4_K_M; `-c 16384 -np 4 -fa on`, KV f16. Chỉ đo hiệu suất. Mọi số liệu là số đo thực.

1. Kết luận

1. **llama.cpp chỉ gom hai luồng vào cùng một bước giải mã khi chúng nằm ở hai slot kề nhau** (0-1, 1-2, 2-3). Khi hai luồng rơi vào slot không kề nhau (0-2, 0-3, 1-3), chúng được giải mã lần lượt và thông lượng tổng bằng một luồng đơn.
2. **Hệ quả đo được (Qwen3-4B):** hai luồng đạt 178 tok/s ở slot kề nhau và 90 tok/s ở slot không kề nhau, chênh gấp 2. Qwen3-8B: 113 và 58 tok/s.
3. **Máy chủ chọn slot theo độ giống với prompt đã lưu trong bộ nhớ đệm**, nên cặp slot phụ thuộc lịch sử yêu cầu: trên server mới hai luồng rơi vào slot 0-1 (nhanh); sau một thời gian chạy, chúng có thể rơi vào cặp không kề nhau (chậm). Đây là lý do bài đo trước ra 93 tok/s và các lần thử trên server mới ra 186 tok/s.
4. **Cờ `--kv-unified` loại bỏ điểm bất thường:** mọi cặp slot đều đạt 167–168 tok/s (4B) và 109 tok/s (8B). Đổi lại, thông lượng 4 luồng giảm 10% (240 so với 268 tok/s) và độ trễ token đầu tệ nhất khi 4 luồng tăng từ 128 lên 414 ms. Một luồng đơn không đổi (101 tok/s).
5. **Production không bị ảnh hưởng ở cấu hình hiện tại:** hồ sơ lập trình dùng một slot (`PARALLEL=1`). Điểm bất thường chỉ xảy ra khi chạy `-np` lớn hơn 1 với 2–3 người dùng đồng thời.

2. Kết quả

Thông lượng tổng, 2 luồng đồng thời, theo cặp slot (tok/s)

Cấu hình	(0,1)	(1,2)	(2,3)	(0,2)	(0,3)	(1,3)
Qwen3-4B, mặc định	177,7	177,8	178,2	**89,9**	**90,0**	**89,7**
Qwen3-4B, `--kv-unified`	167,7	167,1	168,0	168,2	167,3	167,6
Qwen3-8B, mặc định	112,9	không đo	113,2	**58,1**	không đo	không đo
Qwen3-8B, `--kv-unified`	108,6	không đo	108,8	108,9	không đo	không đo

Qwen3-4B, kết quả bài đo đầy đủ (một luồng, 2, 4 luồng)

Chỉ số	Mặc định	`--kv-unified`
Decode một luồng	100,8 tok/s	101,2 tok/s
2 luồng (cặp slot không kề nhau / kề nhau)	92,3 / 178–186	168,7
3 luồng	không đo ở chế độ mặc định	196–207
4 luồng	268,4 tok/s	240,3 tok/s
TTFT tệ nhất khi 4 luồng	128 ms	414 ms

Các cờ khác đã thử trên server mới (Qwen3-4B, `-np 4`): `-np 2`, tắt CUDA graph, `--no-kv-unified`, `--no-cont-batching`, `-b/-ub 512` đều cho 2 luồng 174–186 tok/s ở cặp slot kề nhau; tắt flash attention làm xấu đi mọi mức (một luồng 82 tok/s, 4 luồng 169 tok/s); `-np 1` chỉ xử lý một luồng mỗi lúc (2 luồng 99 tok/s, luồng còn lại xếp hàng) và `-np 2` chỉ xử lý hai luồng mỗi lúc.

3. So sánh nguyên nhân

Hiện tượng	Nguyên nhân
Hai luồng ở slot không kề nhau chậm gấp đôi	Chế độ mặc định của `-np 4` tách KV theo từng slot; bộ chia batch chỉ gom các chuỗi có số slot liên tiếp vào cùng một bước tính (hiện tượng đo được; cơ chế bên trong là suy luận, chưa đọc mã nguồn)
Bất thường chỉ xuất hiện sau một thời gian chạy	Slot được chọn theo độ giống với prompt đã lưu, nên cặp slot phụ thuộc lịch sử
`--kv-unified` hết bất thường	KV dùng chung một vùng cho mọi slot nên không còn ràng buộc slot liên tiếp; giá cả là tổng thông lượng 4 luồng thấp hơn 10%

4. Giới hạn

- Chỉ đo Qwen3-4B (đủ 6 cặp slot) và Qwen3-8B (3 cặp) trên RTX 3060; mỗi cặp một lần sau một lượt khởi động. Chưa đo trên Windows (RTX 5070), nơi bài Foundry Local cũng gặp 2 luồng thấp, nên nhiều khả năng cùng nguyên nhân nhưng chưa kiểm tra theo cặp slot.
- Chưa đo ảnh hưởng của `--kv-unified` ở 8 và 16 luồng, hay khi ngữ cảnh dài.
- Chưa đọc mã nguồn llama.cpp để xác nhận cơ chế ở mục 3.
- Chưa kiểm tra có cách nào ghim yêu cầu vào slot kề nhau từ phía gateway (tham số `id_slot` có hỗ trợ ở máy chủ).