Qwen3.8-27B nhận hình ảnh: cấu hình và đo thử

Ngày 09/11/2026. Cụm RTX 3060 (Linux) + RTX 5070 (Windows), chế độ `merged` 48:52, ngữ cảnh 65536, 1 slot. Số đo thực, một lượt. Mã: `benchmarks/hardware/vision_probe.py`; dữ liệu `benchmarks/reports/vision27b/`.

1. Kết luận

1. **Model nhìn được ảnh** khi nạp thêm bộ chiếu `mmproj-F16.gguf` (927 607 488 byte, sha256 `cbb841a9…0b4e43e` khớp với Hugging Face). File `Qwen3.8-27B-UD-Q4_K_M.gguf` đang dùng không có phần nhìn ảnh.
2. **Không giới hạn số token mỗi ảnh thì không an toàn:** ảnh 1920×1080 làm VRAM card 3060 xuống 461 MiB trống, dưới ngưỡng 512 MiB của worker-guard nên guard dừng engine (engine tự hồi phục khoảng 1 phút; guard còn dừng một container serverless của khách).
3. **Cấu hình triển khai: C** (bộ chiếu ở GPU, `--image-max-tokens 2048`, KV q8_0): 16/16 câu đúng, mỗi ảnh lớn khoảng 5 giây, VRAM 3060 đỉnh 11 135 MiB (còn khoảng 1 150 MiB trống).

2. Ba cấu hình đã so sánh (16 câu: 4 loại câu hỏi × 4 cỡ ảnh)

Cấu hình	Đúng	Giây/ảnh 512 / 1024 / 1080p / 4K	VRAM đỉnh 3060	Ghi chú
A: GPU, tối đa 1024 token/ảnh, KV f16	16/16	1,4 / 2,4 / 2,8 / 2,9	11 717 MiB (còn khoảng 570, sát ngưỡng 512)	nhanh nhưng biên an toàn hẹp
C: GPU, tối đa 2048 token/ảnh, KV q8_0	**16/16**	1,3 / 2,3 / 5,2 / 5,3	**11 135 MiB** (còn khoảng 1 150)	**triển khai**
B: bộ chiếu chạy CPU, tối đa 2048, KV f16	15/16	2,3 / 7,5 / 26,4 / 25,3	10 645 MiB	chậm gấp 5 lần; 1 câu đếm sai (6 thay vì 7) ở 1080p

Bộ câu hỏi: đọc số hóa đơn, đếm 7 hình tròn đỏ, đếm 4 hình vuông xanh, nhận màu hình ở góc trên trái (ảnh tạo bằng PIL, đáp án biết trước). Lưu ý: mỗi câu một lượt, chưa đo ảnh thực tế (ảnh chụp, biểu đồ, tài liệu quét).

3. Kiểm tra đầu cuối qua cổng LAN (cấu hình C)

Phép thử	Kết quả
Ảnh 1080p hóa đơn	đúng (`48213`), 2 060 token, 5,5 giây
Ảnh nhiễu 4K, PNG 24,9 MB	xử lý được (trả lời mô tả), 2 002 token, 6,4 giây
4 ảnh 1080p trong một yêu cầu	đúng (`4`), 8 190 token, 18 giây; VRAM 3060 giữ 11,1 GB
`:think` kèm ảnh	đúng (`Green`), 6,3 giây
Chỉ chữ	bình thường
Body 33 MiB	bị từ chối (kết nối đóng)

Giới hạn body của gateway nâng từ 1 MiB lên 32 MiB và của proxy LAN từ 4 MiB lên 32 MiB.

4. Cách triển khai

- `llama-server-vision` (bộ bọc tại `.aicf-work/bin/`) thêm `--mmproj` cho Qwen3.8-27B, đọc các cờ phụ từ `/mnt/Data/aicf-3node/vision/vision.flags` (hiện là `--image-max-tokens 2048`). Worker-guard không phải sửa mã.
- Guard khởi động với `--llama-server .../llama-server-vision`, KV q8_0, ngữ cảnh 65536.

5. Giới hạn

- KV q8_0 chậm hơn f16 khoảng 3% (ngắn) đến 12% (62k token) như đo ở báo cáo `BAO_CAO_QWEN38_27B_CONTEXT_TOI_UU`.
- Chưa đo chất lượng nhận dạng trên ảnh thực tế và với thinking bật; chưa thử video; mỗi cấu hình một lượt.
- Chưa bền qua khởi động lại máy.