Chạy AI viết code trên 2 máy: nên gộp card hay chạy riêng?

Báo cáo tổng hợp từ 23 cấu hình đo, mỗi cấu hình giải đủ 164 bài lập trình (HumanEval). Đo ngày 06–07/11/2026.

Kết luận nhanh

1 **Model nhỏ thì chạy 1 card.** Gộp 2 card chỉ nhanh hơn 1.12–1.19 lần, nhưng chờ phản hồi đầu tiên lâu hơn 1.4–3.1 lần và tốn điện hơn 5–11% mỗi token (còn -1% đến +10% nếu tính cả điện card rảnh ở chế độ 1 card). Chất lượng không đổi.

2 **Model lớn kiểu MoE 30B thì gộp 2 card.** Nhanh hơn 2.4–3.1 lần so với chạy 1 card (có đẩy bớt sang RAM) và ít tốn điện hơn. Chất lượng giữ nguyên.

3 **Model tốt nhất về cân bằng: Qwen3-Coder-30B (gộp 2 card).** Đúng 154/164 bài (94%), viết 125 token/giây, chỉ 2.2 giây và 382 J điện cho mỗi bài đúng.

4 **Bốn model đầu bảng ngang nhau về chất lượng.** Qwen3.8-27B (158), Qwen3-Coder-30B (154), GLM-4-32B (150), Qwen3-30B-A3B (147): chênh lệch giữa chúng nhỏ hơn mức may rủi. Qwen3.8-27B đúng nhiều nhất nhưng tốn gấp 6.4 lần điện mỗi bài đúng.

5 **DeepSeek không tiết kiệm ở cỡ chạy được trên cụm này.** R1-32B đúng 123/164 nhưng tốn 25,791 J mỗi bài đúng (gấp 68 lần Coder-30B) vì phải viết khoảng 1959 token mỗi bài; V2-Lite chỉ đúng 86 bài. Chữ "tiết kiệm" của DeepSeek nói về giá dịch vụ và model rất lớn, không phải các model tự chạy ở đây.

154/164
bài đúng của Qwen3-Coder-30B

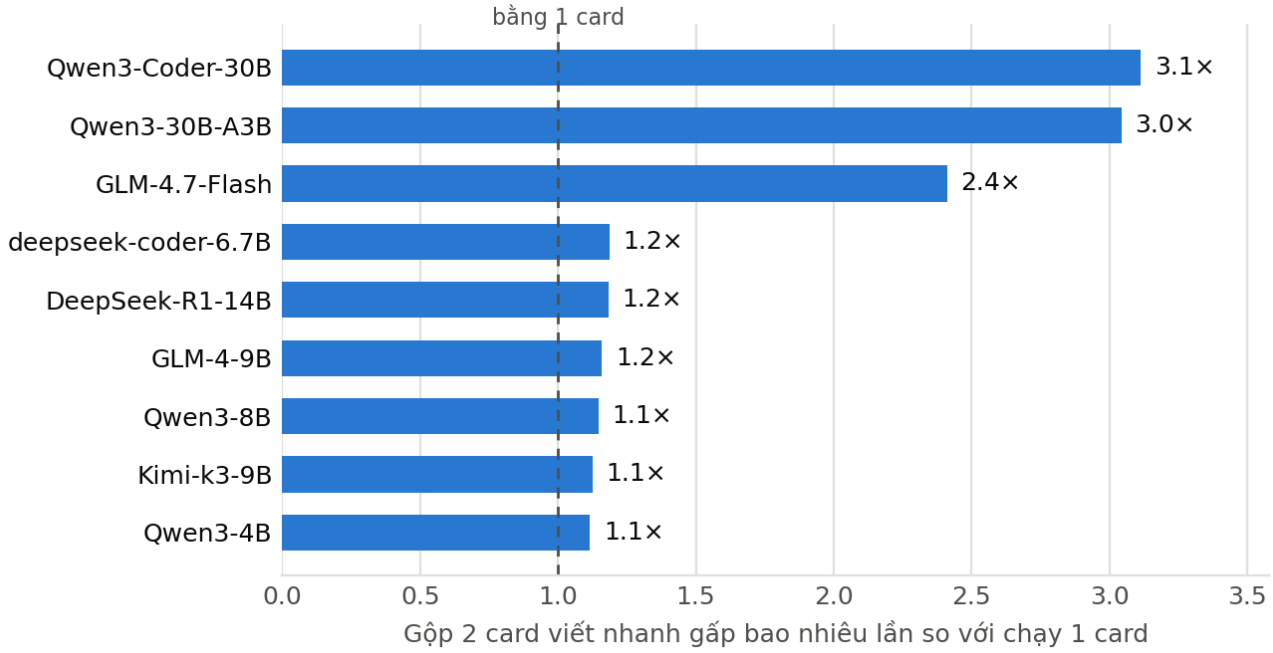
3.1×
nhanh hơn khi gộp 2 card (so với 1 card + RAM)

382 J
điện cho mỗi bài đúng (≈ 0.11 Wh)

Cụm máy và cách đo

- **Hai máy:** máy Linux có card RTX 3060 12 GB và máy Windows có card RTX 5070 12 GB, nối nhau bằng mạng 2,5 Gbps.
- **Hai cách chạy:** *1 card* = model chạy trên 1 máy (model lớn thì đẩy bớt phần phụ sang RAM). *Gộp 2 card* = chia model ra cho cả hai máy qua mạng.
- **Bài đo:** 164 bài viết hàm Python, chấm bằng bộ test tự động. Mỗi cấu hình chạy đủ 164 bài; điện được đo thật trên cả hai card.

1. Gộp 2 card hay chạy 1 card?

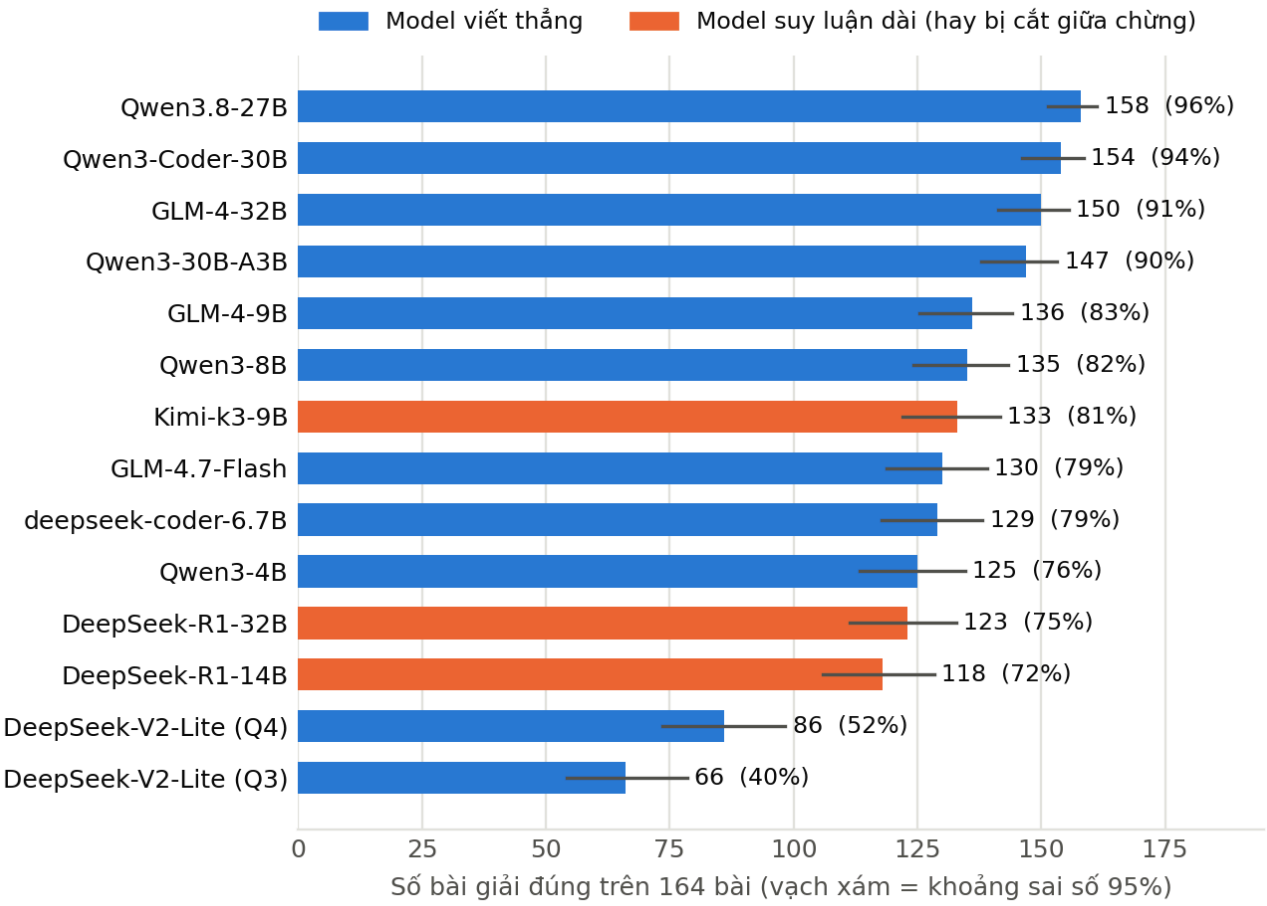


Các model MoE 30B (Qwen3-Coder-30B, Qwen3-30B-A3B, GLM-4.7-Flash) được so với cách chạy 1 card có đẩy bớt sang RAM, vì chúng không vừa 1 card. Các model còn lại so với chạy 1 card thuần.

Loại model	Nên chạy	Vì sao
Nhỏ, vừa 1 card Qwen3-4B/8B, GLM-4-9B, deepseek-coder, Kimi-9B	**1 card**	Gộp chỉ nhanh hơn 1.12–1.19 lần. Phản hồi đầu tiên chậm hơn 1.4–3.1 lần, tốn thêm điện không đáng kể đến khoảng 10%, chiếm cả 2 máy. Để máy kia chạy việc khác hoặc phục vụ người dùng khác.
MoE cỡ 30B Qwen3-Coder-30B, Qwen3-30B-A3B, GLM-4.7-Flash	**Gộp 2 card**	Nhanh hơn 2.4–3.1 lần. Với Coder-30B: 125 so với 40 token/giây, phản hồi đầu tiên 263 so với 744 ms. Số bài đúng như nhau (154 = 154).
Dense lớn 27–32B Qwen3.8-27B, GLM-4-32B	**Gộp 2 card** (không có lựa chọn khác)	Không vừa 1 card. Chạy được nhưng chậm (24 và 21 token/giây) và tốn điện gấp khoảng 6–7 lần Coder-30B.
Sát giới hạn 1 card DeepSeek-R1-14B	**Gộp 2 card**	Trên 1 card chỉ còn dư 53 MiB VRAM; cơ chế bảo vệ của hệ thống đã tắt engine 2 lần trong 164 bài. Gộp 2 card chạy ổn định.

> **Quy tắc nhớ nhanh:** nếu model (kèm bộ nhớ ngữ cảnh) chiếm dưới khoảng 9 GB VRAM thì chạy 1 card; nếu hơn thì gộp 2 card. Gộp 2 card cần mạng khoảng 45–490 Mbit/s khi đang viết, nên mạng 2,5 Gbps dư sức.

2. Model nào viết code đúng nhất?



Mỗi model được tính ở cấu hình gộp 2 card (riêng hai bản DeepSeek-V2-Lite chạy 1 card + RAM vì không gộp được). Vạch xám là khoảng sai số: hai model có vạch chồng lên nhau thì chưa chắc đã khác nhau thật.

Đọc kết quả thế nào

- **Nhóm đầu** (từ 150 đến 158 bài) gồm Qwen3.8-27B, Qwen3-Coder-30B, GLM-4-32B, Qwen3-30B-A3B. Kiểm định thống kê cho thấy bốn model này **không phân biệt được nhau**.
- **Nhóm giữa** (118–136 bài) gồm tám model cũng không phân biệt được nhau. Qwen3-Coder-30B và Qwen3.8-27B hơn cả tám model này.
- **DeepSeek-V2-Lite** yếu hơn hẳn: 86 bài ở bản nén Q4 và 66 bài ở bản nén mạnh hơn Q3. Nén nhẹ hơn cải thiện khoảng 20 bài nhưng model vẫn thấp nhất bảng.
- **Model suy luận dài** (màu cam: DeepSeek-R1-14B, R1-32B, Kimi-9B) **viết rất dài trước khi trả lời** (trung bình 2096, 1959 và 1223 token mỗi bài, so với khoảng 200 của model thường). Phần lớn bài sai là do hết giới hạn 3.072 token giữa chừng, nên điểm của chúng là **mức thấp nhất**. Khi đã nghĩ xong, chúng đúng 98%, 99% và 94%. Bản R1 lớn hơn (32B) chỉ hơn bản 14B khoảng 5 bài, không có ý nghĩa thống kê, mà tốn thêm khoảng 66% điện mỗi bài đúng.
- **Chuyên code** có xu hướng giúp: Qwen3-Coder-30B (154) hơn Qwen3-30B-A3B (147) cùng cỡ, nhưng với 164 bài chưa đủ chắc để khẳng định.

3. Chất lượng so với chi phí



Mỗi chấm là một model ở cấu hình gộp 2 card. Chấm xanh = không có model nào vừa đúng nhiều hơn vừa tốn ít điện hơn.

Chỉ ba model nằm trên đường tối ưu: **Qwen3.8-27B**, **Qwen3-Coder-30B** và **Qwen3-30B-A3B**. Đáng chú ý, Coder-30B (154 bài, 382 J mỗi bài đúng) đúng nhiều hơn Qwen3-4B (125 bài) tới 29 bài mà còn tốn ít điện hơn (408 J). Vậy dùng cả hai card cho model lớn không đắt hơn dùng model nhỏ.

Nên chọn gì?

Nhu cầu	Chọn	Đúng /164	Giây / bài đúng	Điện / bài đúng
Cân bằng chất lượng và chi phí	**Qwen3-Coder-30B**, gộp 2 card	154	2.2	382 J
Tiết kiệm điện nhất trong nhóm mạnh	**Qwen3-30B-A3B**, gộp 2 card	147	1.9	336 J
Chất lượng cao nhất, không ngại chậm	**Qwen3.8-27B**, gộp 2 card	158	12.5	2,455 J
Chỉ có 1 card 12 GB	**GLM-4-9B** hoặc **Qwen3-8B**	132 / 134	2.6 / 3.0	444 / 500 J
Nên tránh (viết code tương tác)	DeepSeek-R1-14B / R1-32B, DeepSeek-V2-Lite (Q4)	118 / 123 / 86	74 / 119 / 9	15,566 / 25,791 / 503 J

Hàng "chỉ có 1 card" lấy số của cấu hình 1 card. Điện chỉ tính phần card đồ họa.

4. Những điều cần lưu ý

- **Chênh vài bài chưa có nghĩa.** Cùng một model, chỉ đổi cách chạy (1 card hay gộp 2 card), vẫn có 4–9 bài trong 164 đổi kết quả (24–27 bài với model suy luận). Vì vậy hai model cách nhau ít hơn khoảng 5 bài thì coi như ngang nhau.
- **Chỉ một bộ đề.** HumanEval có 164 bài Python, công khai từ lâu, nên model có thể đã "gặp" đề khi huấn luyện. Điểm tuyệt đối có thể cao hơn khả năng thật; **thứ hạng tương đối đáng tin hơn con số tuyệt đối**. Chưa đo: sửa code có sẵn, nhiều tệp, ngữ cảnh dài, yêu cầu bằng tiếng Việt.
- **Mỗi cấu hình chỉ đo một lần.** Chưa lặp lại nhiều lần.
- **Điện chỉ tính card đồ họa, và đã kiểm chứng.** So với bộ đếm năng lượng của chính card, cách đo lệch −1,9% (card 3060) và +0,1% (card 5070) trong một đợt thử; cảm biến công bố sai số ±5 W. Chưa có đồng hồ đo ở ổ cắm. Khi chạy "1 card + RAM", CPU làm thêm việc nhưng điện của nó không được đo, nên cách này thực tế tốn điện hơn con số hiển thị. Ở chế độ 1 card, card thứ hai đang rảnh (2–12 W) cũng không được cộng; nếu cộng thì "gộp 2 card tốn điện hơn" chỉ còn từ −1% đến +10% cho các model nhỏ.
- **Điều kiện không hoàn toàn giống nhau.** Qwen3 và GLM-4.7-Flash chạy với chế độ "suy nghĩ" tắt (GLM-4.7-Flash có thể bị đánh giá thấp). Giới hạn độ dài trả lời là 1.024 token (model thường) hoặc 3.072 token (model suy luận).
- **Hai lỗi vận hành đã tìm ra:** (1) model *deepseek-coder* không có sẵn mẫu hội thoại, nên nếu gọi qua giao diện chat thông thường nó không bao giờ dừng viết (đo ban đầu chỉ đạt 60% thay vì 78%); (2) khi chuyển cấu hình bị hỏng, hệ thống có thể kẹt vài phút và từ chối mọi lệnh khác.
- **Cấu hình không chạy được:** DeepSeek-V2-Lite ở chế độ gộp 2 card không nạp được ở cả bản Q3 lẫn Q4 (tiến trình tự thoát, không có thông báo lỗi); nguyên nhân chưa tìm ra. DeepSeek-R1-32B bản Q4_K_M không vừa 2 card ở cấu hình chuẩn, nên đo bản IQ4_XS nhẹ hơn 2,2 GB (ảnh hưởng của việc này tới điểm không tách riêng được).

> **Số liệu cũ cần bỏ.** Báo cáo trước đo chỉ 8–12 bài mỗi model nên sai lệch lớn. Ví dụ deepseek-coder từng được 100% (8/8) nhưng đo đủ 164 bài chỉ đạt khoảng 78%; DeepSeek-R1-14B từng 37,5% nay là khoảng 72–74% do giới hạn token cũ quá thấp; DeepSeek-V2-Lite từng 62,5% (5/8) nay chỉ 40% (Q3) hoặc 52% (Q4).

Muốn kết luận chắc hơn

- Chạy thêm một bộ đề độc lập (ví dụ MBPP, có sẵn trong dự án) hoặc bộ test chặt hơn.
- Lặp lại 2–3 lần cho các cặp model sát nhau.
- Thử model suy luận với giới hạn token lớn hơn.

Phụ lục: toàn bộ 23 cấu hình đã đo

Sắp theo số bài đúng của từng model. "Token/giây" là tốc độ viết (trung vị). "Giây" và "Điện" tính trên mỗi bài đúng.

Model	Cách chạy	Đúng /164	Token/giây	Điện / bài đúng (J)	Giây / bài đúng
Qwen3.8-27B	Gộp 2 card	158	24	2,455	12.5
Qwen3-Coder-30B	Gộp 2 card	154	125	382	2.2
Qwen3-Coder-30B	1 card + RAM	154	40	440	6.8
GLM-4-32B	Gộp 2 card	150	21	2,426	10.9
Qwen3-30B-A3B	Gộp 2 card	147	126	336	1.9
Qwen3-30B-A3B	1 card + RAM	146	41	397	6.0
GLM-4-9B	Gộp 2 card	136	60	461	2.3
GLM-4-9B	1 card	132	51	444	2.6
GLM-4.7-Flash	Gộp 2 card	130	95	506	3.0
GLM-4.7-Flash	1 card + RAM	135	39	536	7.0
Qwen3-8B	Gộp 2 card	135	72	539	2.8
Qwen3-8B	1 card	134	63	500	3.0
Kimi-k3-9B	Gộp 2 card	133	64	4,927	25.4
Kimi-k3-9B	1 card	129	56	4,980	29.5
deepseek-coder-6.7B	Gộp 2 card	129	84	705	4.1
deepseek-coder-6.7B	1 card	128	71	641	3.9
Qwen3-4B	Gộp 2 card	125	112	408	2.3
Qwen3-4B	1 card	128	100	382	2.3
DeepSeek-R1-32B	Gộp 2 card	123	22	25,791	119.2
DeepSeek-R1-14B	Gộp 2 card	118	41	15,566	74.3
DeepSeek-R1-14B	1 card	121	34	13,882	82.1
DeepSeek-V2-Lite (Q4)	1 card + RAM	86	29	503	8.8
DeepSeek-V2-Lite (Q3)	1 card + RAM	66	25	1,134	20.9

DeepSeek-V2-Lite ở chế độ gộp 2 card (cả Q3 và Q4) không nạp được nên không có trong bảng. Dữ liệu chi tiết: *BAO_CAO_FULL164_PHAN_TAN_VS_1_CARD.md* và *BAO_CAO_SO_SANH_CHAT_LUONG_12_MODEL.md* trong thư mục benchmarks/reports.