Đánh giá so sánh: tài liệu kiến trúc và project

Tài liệu: **AI Compute Fabric — Kiến trúc kỹ thuật v1.0** (25/10/2026) · Project: `ai-compute-fabric`, trạng thái 07/11/2026 (167 commit) · Ngôn ngữ: tiếng Việt

> **Kết luận ngắn.** Phần lõi "một máy – hai máy" của tài liệu đã được hiện thực và đo thật, thường vượt kỳ vọng: gateway, worker, lease, thu hồi GPU, ghép hai card qua RPC, MoE, Agent, RAG, ASR, LoRA. Phần "quy mô lớn" gần như chưa có bằng chứng: nhóm 3–4 node, 40–200 PC, federation qua WAN thật, DDP thật, Prima.cpp và MoLink. Đồng thời dự án đã làm thêm một khối lớn không nằm trong tài liệu (serverless GPU, AI Studio, Best-of-N, tích hợp IDE/CLI). Mức hoàn thành theo các hạng mục của tài liệu: khoảng **68%** [ƯỚC TÍNH, cách tính ở dưới].

33	1	24	10
Đã làm (49%)	Làm khác tài liệu (1%)	Một phần (35%)	Chưa làm (15%)



Tổng 68 hạng mục trích từ tài liệu. Điểm = (đã làm + làm khác + 0,5 × một phần) / tổng. Đây là phán đoán của người đánh giá, các hạng mục không cùng trọng số, nên chỉ dùng để thấy xu hướng.

1. Cách đối chiếu và mức tin cậy

- **[ĐỌC MÃ]**: tôi đọc file trong repo. **[ĐO]**: số có sẵn trong `benchmarks/reports` hoặc lệnh chạy ngày 07/11/2026. **[ƯỚC TÍNH]**: phán đoán.
- Kiểm thử chạy lại hôm nay: `go test` pass ở 5 module (site-gateway, worker-guard, global-control-plane, vram-estimator, contracts); `pytest` trên unit + security + correctness + resilience cho kết quả **356 pass, 16 skip, 1 xfail**. Bộ integration, studio và serverless cần dịch vụ chạy nền nên không chạy lại.
- Quy mô mã không-test đếm bằng wc: apps ~12 nghìn dòng Go/Py, agents ~5,6 nghìn, benchmarks ~15,8 nghìn, tests ~11,8 nghìn, serverless ~3,1 nghìn, studio ~2,7 nghìn.
- Không chạy lại các benchmark GPU cũ; các số trong báo cáo được trích nguyên văn từ file kết quả.

2. So sánh chi tiết theo từng phần của tài liệu

Yêu cầu trong tài liệu	Trạng thái	Bằng chứng trong project
§2 Kiến trúc — 2 đã làm · 0 làm khác · 6 một phần · 0 chưa		
Site Gateway (Go + gRPC): registry, lease, link graph, policy, cache	**Đã làm**	apps/site-gateway: Register/Heartbeat, LeaseService, router WFQ + KV affinity + deadline, mTLS, RBAC, audit chuỗi băm SHA-256 [ĐỌC MÃ]; go test pass [ĐO]
PC Worker Agent: profiling, quota, idle, sandbox, signed job, heartbeat (Windows/Linux)	**Một phần**	apps/worker-guard: đọc VRAM thật, thu hồi GPU, heartbeat 6-bucket, Windows service. Chưa thấy signed job; quota CPU/RAM mới ở mức gắn nhãn CPU [ĐỌC MÃ]

Yêu cầu trong tài liệu	Trạng thái	Bằng chứng trong project
Global Control Plane: chính sách, metering, federation	Một phần	apps/global-control-plane: mTLS 1.3, thu hồi serial, DataClass, sổ cái bất biến; test đơn vị pass. Chưa chạy qua WAN/nhiều site thật [ĐỌC MÃ]
Inference Runtime: llama.cpp là mặc định; Prima/MoLink đối chứng; KT/vLLM có điều kiện	Một phần	llama.cpp chạy production, vLLM/SGLang chỉ để đối chứng (P10–P13). Prima/MoLink chưa tích hợp
Agent Runtime: LangGraph + Fabric task API	Đã làm	agents/orchestrator.py (LangGraph), task_bus.py (NATS JetStream), dag_api.py
Audio & Training: ASR/TTS, fine-tune, DiLoCo, đánh giá	Một phần	Có ASR, LoRA, mô phỏng DiLoCo; TTS/enhancement/DDP chưa đúng như tài liệu (xem §7)
Observability & Data: Postgres, object storage, NATS, OpenTelemetry	Một phần	Postgres/pgvector + NATS có; /metrics và audit log có; chưa có OpenTelemetry, Grafana, object storage
Ba mặt phẳng control / data / management (cert rotation, provisioning)	Một phần	Control và data tách rõ; chứng chỉ do công cụ pki cấp tay, leaf hết hạn 25/01/2027, chưa tự xoay vòng
§3 Luồng — 3 đã làm · 0 làm khác · 1 một phần · 0 chưa		
Luồng một yêu cầu Qwen: xác thực tenant, định tuyến, lease, stream, metrics, failover	Đã làm	/v1/chat/completions qua gateway → router → worker; test affinity, fairness, inference_load
Định danh model bằng hash weights + tokenizer + revision	Đã làm	ModelIdentity (proto), core/model_registry/provenance.py, scheduler từ chối MODEL_IDENTITY_MISMATCH
Workflow AI Agent → DAG task có kiểu → gộp kết quả	Đã làm	agents/ (15 typed task, validator), p5_agent_dag_e2e.json (DAG 14 bước)
Job fine-tune audio: manifest → kiểm quyền → tách speaker → train → cổng WER/CER → đăng ký artifact	Một phần	audio/ingestion có tách speaker và manifest; cổng chất lượng và đăng ký model chưa thành quy trình khép kín
§4 Engine — 3 đã làm · 1 làm khác · 3 một phần · 2 chưa		

Yêu cầu trong tài liệu	Trạng thái	Bằng chứng trong project
LOCAL_REPLICA: Qwen nhỏ trên từng PC, nhiều PC phục vụ song song	**Đã làm**	Chế độ split: Qwen3-4B 554,9 tok/s tổng với 4 luồng/máy [ĐO]; 2 node chạy song song scale 96,4% [ĐO]
LOCAL_HYBRID: GPU + RAM, expert nóng/lạnh cho MoE	**Đã làm**	smart_1gpu với -ncmoe; B06 trên RTX 3060; Qwen3-30B-A3B 44 tok/s ở 8k [ĐO]
DISTRIBUTED_MODEL bằng Prima.cpp / MoLink	**Chưa làm**	Chỉ có dòng trong upstream-manifest.yaml (license UNVERIFIED); không có adapter hay benchmark B04/B05
DISTRIBUTED_MODEL: chạy được model vượt VRAM một máy bằng nhóm 2 node	**Làm khác tài liệu**	Làm bằng GGML RPC của llama.cpp (chế độ merged): Qwen3-30B-A3B ~135 tok/s, gấp 2,1× (ctx 8k) và 2,7× (ctx 32k) RTX 5070 đơn lẻ [ĐO, README]. Tài liệu coi RPC chỉ là proof-of-concept
Nhóm 3–4 PC cùng một model	**Chưa làm**	Mới có 2 máy (RTX 3060 + RTX 5070); chưa thử 3–4 node
SPECULATIVE decoding	**Một phần**	B07: Qwen3-8B + draft 0,6B nhanh 1,185×, acceptance 0,49, nhưng đầu ra giống baseline chỉ 25% [ĐO]. Chưa đưa vào production
Native MoE và distributed native MoE (bảo toàn phép tính)	**Đã làm**	Qwen3-30B-A3B và Coder-30B chạy native, merged 2 card; full-164 HumanEval 154/164 cho Coder-30B [ĐO]
Agent-level experts (router chọn Agent theo loại việc)	**Một phần**	Có Best-of-N cho code và Agent task; chưa có router chọn expert-agent đúng mô tả
KTransformers (cổng ISA, backend riêng)	**Một phần**	P8: đo baseline và micro-benchmark kt-kernel, cổng CPU ISA trong core/hardware_profiler; chưa tích hợp làm backend
§5 Scheduler — 3 đã làm · 0 làm khác · 2 một phần · 1 chưa		
Lọc cứng + chọn argmin thời gian dự kiến (bộ nhớ, identity, residency, SLA)	**Đã làm**	core/adaptive_scheduler/scheduler.py (74 dòng, thuần logic), unit test pass
Scheduler chi phí nói trên được cắm vào đường định tuyến thật	**Một phần**	Chỉ test import module này. Gateway thật dùng WFQ + affinity + priority + deadline (router.go), không dùng hàm chi phí [ĐỌC MÃ]
Đường cong benchmark theo (model, backend, phần cứng) + predictor học từ dữ liệu	**Chưa làm**	Chưa có predictor; số đo nằm trong báo cáo, không nạp lại vào scheduler

Yêu cầu trong tài liệu	Trạng thái	Bằng chứng trong project
Lease có TTL, gia hạn bằng heartbeat; nhường PC cho người dùng	Đã làm	leases.go; thu hồi GPU trung vị 174 ms (Windows), 273 ms (Linux) < 2 s [ĐO]
Chống quá tải: quota tenant, giới hạn đồng thời, backpressure	Đã làm	Tenant fairness benchmark, MaxQueue, max_inflight; test fair/leases
3 mức ưu tiên: người dùng > doanh nghiệp > federation	Một phần	Mức 1 làm tốt (thu hồi GPU); mức doanh nghiệp/federation có chính sách nhưng chưa đo dưới tải thật
§6 Agent — 6 đã làm · 0 làm khác · 2 một phần · 0 chưa		
Graph Orchestrator (LangGraph) + checkpoint	Đã làm	agents/orchestrator.py, task_bus.py
Task Planner tách mục tiêu thành DAG kiểu	Một phần	Orchestrator dựng DAG; chưa có module planner riêng
Tool Registry (allowlist có kiểu) và không có shell tổng quát	Đã làm	agents/tool_registry.py; test an ninh pass
Task Executor + sandbox	Đã làm	agents/sandbox.py (bubblewrap/Docker); p7_pha0_sandbox_mutation.json
Knowledge Service: chunking, pgvector, rerank, cô lập tenant	Đã làm	agents/knowledge.py; p5_rag_quality_small_vi.json
Result Validator	Đã làm	agents/validator.py
15 loại task chuẩn	Đã làm	tests/unit/test_15_typed_task_schemas.py
Ví dụ phân tích 10.000 cuộc gọi chạy thật	Một phần	Các mảnh (VAD, ASR, trích xuất, RAG) có; chưa có lần chạy quy mô lớn
§7 Audio — 1 đã làm · 0 làm khác · 2 một phần · 1 chưa		
ASR bằng Qwen3-ASR	Đã làm	Qwen3-ASR-0.6B: WER 8,1% trên 100 clip FLEURS tiếng Việt [ĐO]
TTS bằng Qwen3-TTS	Một phần	Vòng TTS→ASR dùng mms-tts-vie, không phải Qwen3-TTS
Enhancement bằng DeepFilterNet	Một phần	Đang là cổng phổ numpy; WER nhiễu 13,6% → 12,9% [ĐO]
Nhận diện sự kiện âm thanh (BEATs)	Chưa làm	Không có
§7 Training — 2 đã làm · 0 làm khác · 1 một phần · 1 chưa		
LoRA/PEFT một GPU	Đã làm	training/lora_trainer.py, QLoRA trong Studio, memory estimator đã khớp thực đo

Yêu cầu trong tài liệu	Trạng thái	Bằng chứng trong project
Quy tắc gộp LoRA không lấy trung bình A và B tùy tiện	Đã làm	training/lora_merger.py: naive, exact, lora_fa, svd
DDP 2–4 GPU thật	Chưa làm	Chỉ có mô phỏng: 4 worker chạy tuần tự trên một RTX 3060
DiLoCo thử nghiệm	Một phần	p6_diloco_vs_ddp: 2 seed, lưới lr, chọn theo validation; nhưng chạy tuần tự một GPU, chưa đa máy
§8 Hạ tầng — 2 đã làm · 0 làm khác · 2 một phần · 1 chưa		
PostgreSQL + pgvector	Đã làm	agents/knowledge.py (psycopg, pgvector)
NATS JetStream (at-least-once, idempotent)	Đã làm	agents/task_bus.py, tests/integration/test_task_bus.py
Object storage cho checkpoint / model shard	Chưa làm	Dùng thư mục cục bộ; chưa có kho đối tượng
Model Registry có artifact ký số	Một phần	Hash, provenance, kiểm trust_remote_code có; ký model chưa có (cosign chỉ dùng cho SBOM)
Metrics/traces: OpenTelemetry, Prometheus, Grafana	Một phần	Có /metrics và /api/stats; không có OpenTelemetry/Grafana
§9 WAN — 1 đã làm · 0 làm khác · 1 một phần · 1 chưa		
AdvertiseCapacity / OfferJob / AcceptJob / ReportUsage	Một phần	apps/global-control-plane/plane.go + test; chưa có proto riêng
mTLS liên site, thu hồi chứng chỉ, DataClass không rời site gốc	Đã làm	plane.go, policy.go; gcp_test, pki_test pass
Pilot federation 2–3 site thật	Chưa làm	Chưa có; chỉ test đơn vị
§10 Monorepo — 1 đã làm · 0 làm khác · 2 một phần · 1 chưa		
upstream-manifest: commit ghim, SPDX, người phụ trách	Một phần	Có file với SHA ứng viên; legal_reviewed=false cho mọi mục, 3 mục license UNVERIFIED
NOTICE và SBOM ký cosign	Đã làm	NOTICE, Makefile verify, tests/security/test_sbom_signatures.py
third_party/patches và pinned-forks	Chưa làm	Thư mục chỉ có upstream-manifest.yaml
Cấu trúc thư mục theo Phụ lục A	Một phần	Có apps/core/inference/agents/audio/training/contracts/benchmarks; federation/, infrastructure/, inference/moe, speculative, audio/asr, tts rỗng
§11 Contract — 3 đã làm · 0 làm khác · 0 một phần · 1 chưa		

Yêu cầu trong tài liệu	Trạng thái	Bằng chứng trong project
Protobuf: WorkerCapacity, ModelIdentity, WorkloadJob, Lease; Fleet + Lease service	Đã làm	contracts/protobuf/aicf/v1 + golden test
Service Placement, Inference, AgentJobs, Training, Federation (proto)	Chưa làm	Chưa có proto; các API này tồn tại dưới dạng REST/Go struct
OpenAPI v1 kiểm tự động theo route	Đã làm	contracts/openapi/aicf_v1.yaml
Engine lifecycle 7 hàm (probe…stop) + adapter	Đã làm	inference/engine.py; adapter llama, vllm (sglang/prima/molink chưa có)
§13 An ninh — 2 đã làm · 0 làm khác · 1 một phần · 1 chưa		
mTLS, RBAC, audit, tenant isolation	Đã làm	mtls.go, rbac.go, audit.go; tests/security 29 ca
Cấm generic shell, allowlist tool, sandbox, không trust_remote_code	Đã làm	tool_registry, sandbox, model_registry/security.py
Kiểm toán giấy phép model Qwen, dataset giọng nói, mã nguồn	Chưa làm	legal_reviewed=false; chưa có kết quả rà soát
Không để LAN mặc định tin cậy / không lộ RPC	Một phần	Mật khẩu admin mặc định 'Admin@AICF2026!' nằm trong deploy/demo/run_demo.sh; 'demo-admin-token' còn là giá trị dự phòng ở nhiều script; cổng GGML RPC không có xác thực. Đã dựng proxy lọc cho LAN nhưng chưa là cấu hình mặc định [ĐỌC MÃ]
§15 Kiểm thử — 2 đã làm · 0 làm khác · 1 một phần · 0 chưa		
Bộ kiểm thử theo tầng (unit, integration, correctness, resilience, security)	Đã làm	356 pass, 16 skip, 1 xfail trên unit+security+correctness+resilience; go test pass 5 module [ĐO 07/11]
Performance và audio-quality trong thư mục tests/	Một phần	tests/performance và tests/audio_quality rỗng; benchmark nằm ở benchmarks/
CI tự động	Đã làm	.github/workflows/ci.yml, Makefile verify-release-v1
§14 Deliverable — 2 đã làm · 0 làm khác · 0 một phần · 0 chưa		
ADR cho từng quyết định lớn	Đã làm	docs/adr: 4 ADR (GPUStack, bus, serverless, web editor)

Yêu cầu trong tài liệu	Trạng thái	Bằng chứng trong project
Machine inventory + baseline vLLM TP/PP	Đã làm	p0_probe_*.json; P10–P13 (vLLM/SGLang PP, 2 GPU)

3. Ma trận benchmark B01–B09 (mục 12.4 của tài liệu)

Mã	Tài liệu yêu cầu	Trạng thái	Thực tế
B01	1 PC, Qwen nhỏ: TTFT, TPOT, joule/token, VRAM	Đã làm	llama-bench Qwen3-4B/8B trên 3060 và 5070; joule/token đo ở full-164 (đối chiếu NVML sai −1,9% / +0,1%)
B02	1 PC, Qwen lớn + offload RAM	Đã làm	Qwen2.5-32B Q4 trên 3060 (p0_B02)
B03	3–4 PC, vLLM TP/PP baseline	Một phần	Chỉ 2 GPU; vLLM/SGLang PP qua WSL2 (P10–P13); đa nút vLLM không chạy được qua NAT của Windows 10
B04	3–4 PC, Prima.cpp	Chưa làm	Chưa làm
B05	3–4 PC, MoLink	Chưa làm	Chưa làm
B06	Qwen MoE local / hybrid	Đã làm	p4_B06: Qwen3-30B-A3B với n-cpu-moe 48→0
B07	Speculative target/draft	Đã làm	p4_B07: 1,185×, acceptance 0,49; lưu ý đầu ra không giống baseline
B08	8–40 PC, Agent task độc lập	Một phần	Mô phỏng worker (hiệu suất 85,5% / 74,1% / 56,8% ở 8 / 20 / 40) ghi rõ SIMULATED; thật mới 2 máy, scale 96,4%
B09	4–8 PC, audio training DDP/DiLoCo	Một phần	Mô phỏng 4 worker tuần tự trên một GPU

Tài liệu yêu cầu thêm: prompt 512/4096, concurrency 1/8/32, hai mức LAN, tối thiểu 3 lần warm + 5 lần đo, có tải nền và một worker rời mạng. Chuỗi full-164 và các benchmark P3 đã có lặp lại và thống kê, nhưng không phải mọi B-test đều đủ ma trận này.

Cổng nghiệm thu hiệu năng (mục 12.5)

Mục tiêu / chỉ số	Kết quả hiện có
Distributed Qwen: giảm TPOT ≥30% so với PP baseline, hoặc chạy được model không vừa máy đơn	Đạt theo vế thứ hai: Qwen3-30B-A3B (18,6 GB) chạy 100% trong VRAM hai card, 135 tok/s; Coder-30B 154/164 HumanEval. Chưa so TPOT với PP baseline cũ cùng điều kiện [ĐO]
Task parallel: tổng throughput ≥80% tổng các node độc lập	Đạt ở 2 node thật (96,4%); ở 40 worker mô phỏng chỉ 56,8%, chưa kiểm chứng ở quy mô 40+ thật [ĐO]
Ưu tiên tài nguyên: không chiếm ngoài quota, thu hồi giữa task	Đạt về thu hồi GPU (< 2 s, 10/10 lần trên Windows); chưa thử dưới tải người dùng thật kéo dài
Audio training: thời gian đến target WER/CER không xấu hơn baseline	Chưa đo trên đa máy; có so sánh DiLoCo với DDP theo perplexity trên một GPU

4. Lộ trình P0–P6 so với thực tế

Giai đoạn	Trạng thái	Ghi chú
P0 Audit & baseline	Đã làm	Probe phần cứng, baseline llama.cpp và vLLM/SGLang đều có. Thiếu: rà soát license.
P1 Worker Fabric	Một phần	Agent, Gateway, registry, lease, NATS, adapter llama.cpp có. Cổng '5–20–40 node ổn định' chưa đạt: mới 2 máy thật.
P2 Distributed Qwen	Một phần	Topology planner + merged qua RPC có và đo tốt; Prima/MoLink không làm; so sánh 3–4 RTX 3060 chưa làm.
P3 MoE & AI Agent	Đã làm	MoE native/hybrid, LangGraph, RAG, ASR, tool, sandbox đều có test. Quota Agent mới ở mức tenant.
P4 Audio & DiLoCo	Một phần	ASR, LoRA, DiLoCo mô phỏng. Chưa có TTS Qwen, DDP thật, báo cáo hội tụ đa máy.
P5 Pilot 200 PC / WAN	Chưa làm	Chưa có pilot, chưa có federation 2–3 site, chưa review bảo mật độc lập.
P6 Production hardening	Một phần	Release manifest, SBOM ký, runbook SRE, CI có. Còn: pin thật, legal, DR, đổi token mặc định.

5. Những gì project đã làm thêm ngoài tài liệu

Hạng mục	Quy mô / bằng chứng
Serverless GPU kiểu Modal	serverless/ + agents/sl_*.py (~3,1 nghìn dòng Python), SDK Python (~1,5 nghìn dòng), 14 file test (184 ca), ADR-003
AI Studio: RAG, QLoRA, ước tính full-FT, prompt/few-shot	studio/ (~2,7 nghìn dòng), tests/studio 45 ca
Best-of-N cho viết code + API cho IDE	bestofn/ (~1,8 nghìn dòng), P7_BEST_OF_N.md
Web IDE (CodeMirror) và dashboard 200-GPU	apps/site-gateway/web (~8,8 nghìn dòng JS/HTML), ADR-004
Giả lập Ollama + OpenAI Responses, trang kích hoạt một chạm, cầu nối Windows/Linux/macOS	ollama_emulator.go (~1,3 nghìn dòng), bridge/*.tmpl, connect.html; thử thật với Codex CLI và GJC
Windows Agent (điều khiển ứng dụng qua UIA)	windows-agent/ (~1,5 nghìn dòng), so sánh với UFO2, goose, UI-TARS
Benchmark HumanEval 164 bài × 23 cấu hình, gồm thống kê McNemar + Holm và đo điện	benchmarks/reports/full164, 3 báo cáo + PDF tổng hợp
Tối ưu CPU affinity / KV q8 / ncmoe, nghiên cứu nghẽn SGLang PP	P9, P12, P13 và các kế hoạch KE_HOACH_*.md

Nhóm này chiếm tỷ trọng lớn trong khối lượng mã. Ngược lại, tài liệu dành nhiều trang cho engine (Prima, MoLink, KTransformers, Exo, Parallax) mà project hầu như chưa dùng. Phạm vi thực tế đã dịch từ "hạ tầng tính toán phân tán" sang "nền tảng phục vụ AI cho nhóm nhỏ trên hai máy GPU".

6. Đánh giá chung về tài liệu so với project

Điểm mạnh

- Giữ kỷ luật bằng chứng: tách rõ thiết kế với kết quả, ghi 'chưa phải benchmark', và đòi cùng model/tokenizer/quantization khi so sánh.
- Bốn nguyên tắc cốt lõi đã đứng vững qua thực nghiệm: phân tán chỉ để chạy được model lớn hoặc để nhanh hơn; MoE nên hybrid trước khi gọi expert từ xa; không đặt activation theo từng token qua WAN; LoRA không được lấy trung bình A và B.
- Phần cứng giả định (RTX 3060 12 GB, LAN 2–5 Gbps) khớp với thiết bị thật; con số suy hao (54,9 ms/token, 218 ms/token) giúp định hướng sớm.
- Có cổng nghiệm thu, ma trận B01–B09, Definition of Done cho mỗi engine, nên rất dễ đối chiếu như báo cáo này.
- Phụ lục C liệt kê đúng những câu hỏi hóa ra quyết định thành bại (3060 12 GB hay 8 GB, băng thông LAN theo từng PC, baseline TP/PP đã chạy).

Điểm yếu và chỗ lệch với thực tế

Vấn đề	Nhận xét
Chưa dự đoán được trở ngại Windows	Tài liệu ngầm xem các PC như Linux. Thực tế vLLM/SGLang đa nút không chạy qua NAT của WSL2 trên Windows 10, Prima/MoLink chưa có hỗ trợ Windows đã xác minh. Đây là lý do chính hai engine này không vào được dự án.
Hướng 'GGML RPC chỉ là PoC' lệch với kết quả	Cuối cùng RPC lại là đường phân tán duy nhất đạt mục tiêu (~135 tok/s, 2,1–2,7× RTX 5070 đơn lẻ). Tài liệu nên đổi thành 'RPC là đường mặc định cho nhóm 2 node trong LAN tin cậy, kèm điều kiện mạng và cách ly'.
Quá nhiều engine so với nhân lực	Hơn 7 engine/backend ứng viên (llama.cpp, Prima, MoLink, vLLM, SGLang, KTransformers, Exo, Parallax) cho 3 mức phần cứng. Dự án thực tế chỉ cần llama.cpp là chính và đối chứng vLLM/SGLang.
Ngầm cho rằng sẽ có 200 PC	Mọi KPI phân tán lớn (40+ node, pilot 200 PC) đều không kiểm chứng được trên hai máy; tài liệu nên có một bậc 'hai máy' làm đích rõ ràng cho giai đoạn đầu.
Thiếu các sản phẩm trọng yếu mà dự án phải làm	Không đề cập serverless GPU, AI Studio, Best-of-N cho code, tích hợp IDE/CLI (Codex, GJC, Ollama). Tổng cộng đây là khoảng một nửa khối lượng mã thực tế.
API quá rộng so với giá trị	Bảy service proto (Placement, Inference, AgentJobs, Training, Federation…) chưa cần khi mới 2 máy; dự án dùng REST + hai proto là đủ và đã chạy.
Lộ trình theo sprint không còn phù hợp	Dự án tới trạng thái 'release v1.1' sau khoảng hai tuần (167 commit từ 25/10 đến 07/11), nhanh hơn nhiều so với ước tính 12–22 sprint cho P0–P5 (chưa tính P6), nhưng bỏ qua phần pilot và pháp lý. Cần viết lại lộ trình theo giá trị còn thiếu.
Chưa nói về vận hành và chi phí	Không có phần về giá thành điện/GPU-giờ, SLO người dùng, cách phát hành cập nhật cho PC, hay mô hình đối soát tài nguyên, trong khi dự án đã đo joule/token.

Đánh giá tổng quát [ƯỚC TÍNH]. Là bản thiết kế, tài liệu tốt về nguyên tắc và kỷ luật đo đạc, và những nguyên tắc đó đã thật sự dẫn đường cho project. Điểm yếu là phạm vi và giả định quy mô (200 PC, 7 engine, Linux đồng nhất) vượt xa nguồn lực và phần cứng hiện có. Tài liệu cần được cập nhật thành v2 theo thực tế hai máy, không phải bỏ đi.

7. Rủi ro hiện tại của project

Mức	Rủi ro	Chi tiết
Cao	**Mặc định bảo mật yếu**	run_demo.sh sinh token ngẫu nhiên khi dùng giá trị mặc định, nhưng mật khẩu admin mặc định 'Admin@AICF2026!' nằm sẵn trong mã nguồn và 'demo-admin-token' còn là giá trị dự phòng ở nhiều script; GGML RPC không xác thực. Cần đổi trước khi mở rộng ngoài hai máy.
Cao	**Chưa rà soát giấy phép**	legal_reviewed=false cho mọi upstream và 3 mục UNVERIFIED (prime-diloco, prima.cpp, MoLink); chưa có kiểm toán license model Qwen và dữ liệu giọng nói.
Trung bình	**Scheduler chi phí chưa vào đường chạy**	Hàm argmin đã có test nhưng gateway thật không dùng; số đo không được nạp ngược để dự đoán.
Trung bình	**Chưa chứng minh ở quy mô nhiều node**	Mọi kết quả đa máy từ hai máy; số 40 worker là mô phỏng.
Trung bình	**Speculative decoding đổi đầu ra**	Chỉ 25–33% đầu ra giống baseline ở B07; chưa được bật production, cần giữ như vậy cho tới khi kiểm đúng phân phối.
Trung bình	**VRAM rất sát ở chế độ ghép 2 card**	Sau khi tăng ngữ cảnh lên 20.480 token: 3060 dùng 11,2/12,3 GB, 5070 dùng 11,5/12,2 GB [ĐO 07/11]. Còn ít dư cho tải khác trên máy Windows.
Thấp	**Dung lượng đĩa**	Ổ C: Windows từng đầy 100% (đã dọn 17 GB); đĩa dự án Linux gần đầy theo ghi nhận trước.

8. Đề xuất ưu tiên

1. Bỏ mật khẩu admin mặc định trong run_demo.sh và các giá trị 'demo-admin-token' dự phòng; đặt proxy lọc làm cấu hình mặc định khi mở LAN; thêm xoay vòng chứng chỉ trước 25/01/2027.
2. Rà soát giấy phép (upstream, model Qwen, dữ liệu giọng nói) và thay SHA 'ứng viên' bằng bản đã đo; chốt Prima/MoLink là 'bỏ' hoặc 'làm tiếp' theo kết luận Windows.
3. Nối scheduler chi phí vào router (bắt đầu bằng chế độ shadow: chỉ ghi lại quyết định so với WFQ) và nạp số đo B01/B06/full-164 làm đường cong.
4. Thêm máy thứ ba để kiểm chứng nhóm 3 node và B03/B08 thật; nếu chưa có máy, ghi rõ KPI nhiều node là 'chưa kiểm chứng'.
5. Viết lại tài liệu kiến trúc v2: hai máy là đích đầu, RPC làm đường phân tán chính, đưa serverless/Studio/IDE vào phạm vi, rút gọn danh sách proto.
6. Bổ sung quan sát: OpenTelemetry hoặc ít nhất Prometheus + dashboard, vì dự án đã có /metrics và số đo năng lượng.

Phụ lục. Giới hạn của báo cáo này

- Tôi đọc kỹ docx (228 đoạn, bảng) và khảo sát repo bằng grep, đọc file và chạy test. Tôi không đọc từng dòng của toàn bộ ~50 nghìn dòng mã, nên "đã làm" nghĩa là có mã và bằng chứng đo hoặc test tương ứng, không phải xác nhận mọi nhánh.
- Hình ảnh trong docx (2 ảnh) không được phân tích.
- Các con số hiệu năng lấy từ báo cáo của project; không đối chiếu độc lập với tài liệu gốc ngoài các phép kiểm NVML đã làm trước đó.